

Poisson Image Editing 的实现

I. 简介

泊松图像编辑是一种利用泊松方程解决图像编辑问题的方法，由 Microsoft Research UK 的 Patrick Perez, Michel Gangnet, and Andrew Blake 在论文 “Poisson Image Editing” 中首次提出。

II. 算法说明

A. 哈密顿算子、拉普拉斯算子、梯度与散度

哈密顿算子

$$\nabla = \frac{\partial}{\partial x} \vec{i} + \frac{\partial}{\partial y} \vec{j} + \frac{\partial}{\partial z} \vec{k}$$

拉普拉斯算子

$$\Delta = \nabla \cdot \nabla = \nabla^2 = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} + \frac{\partial^2}{\partial z^2}$$

(拉普拉斯算子可以定义为梯度的散度)

梯度

$$\text{grad}(A) = \nabla A = \frac{\partial A}{\partial x} \vec{i} + \frac{\partial A}{\partial y} \vec{j} + \frac{\partial A}{\partial z} \vec{k}$$

散度

$$\text{div}(\vec{A}) = \nabla \cdot \vec{A} = \frac{\partial A_x}{\partial x} + \frac{\partial A_y}{\partial y} + \frac{\partial A_z}{\partial z}$$

B. 图像中的运算

在图像中，通常使用差分来近似导数，最简单的一种梯度表示方式如下

$$\text{Grad}_x(x, y) = P(x+1, y) - P(x, y)$$

$$\text{Grad}_y(x, y) = P(x, y+1) - P(x, y)$$

因此我们对梯度求散度的话，有

$$\text{Div}(x, y) = \text{Grad}_x(x+1, y) - \text{Grad}_x(x, y) + \text{Grad}_y(x, y+1) - \text{Grad}_y(x, y)$$

拉普拉斯算子可以定义为梯度的散度，所以拉普拉斯算子在图像中的运算可以表示为如下形式

$$\begin{aligned} \text{laplacian}(x, y) &= P(x+1, y) - P(x, y) - P(x, y) \\ &\quad + P(x-1, y) + P(x, y+1) - P(x, y) \\ &\quad - P(x, y) + P(x, y-1) \end{aligned}$$

也即

$$\text{laplacian}(x, y) = P(x+1, y) + P(x-1, y) + P(x, y+1) + P(x, y-1) - 4P(x, y)$$

写成矩阵有如下形式，其中 P 代表像素点 (x, y) 的八邻域，这里并不是矩阵乘法运算，而是对应元素相乘然后累加。

$$\text{laplacian}(x, y) = \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix} P$$

C. 泊松图像编辑的基本思想

将背景图片记作 S，将前景图片记作 G，在 S 中插入 G 的对应区域 Ω 记作 f^* ， Ω 的边界是 $\partial\Omega$ (不含有 Ω)，G 的梯度图记作 v 。

在将 G 嵌入到 S 的 Ω 区域时，Patrick Perez 等人提出在保证边界不变 (即 $\partial\Omega$ 的像素点是属于 S 的) 的前提下，使得合成后图片 Ω 区域 (记作 f) 的梯度值与原图的梯度值的差值最小。即

$$\min \iint_{\Omega} |\nabla f - v|^2, \quad f|_{\partial\Omega} = f^*|_{\partial\Omega} \quad \text{---①}$$

(论文公式 3)

这个方程的解是满足狄里克雷边界条件的泊松方程，即

$$\Delta f = \text{div} v, \quad f|_{\partial\Omega} = f^*|_{\partial\Omega} \quad \text{---②}$$

(论文公式 4)

由于图像是二维离散的数据值，所以公式可以变化为

$$\begin{aligned} f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) \\ - 4f(x, y) = \text{div} v \quad \text{---③} \end{aligned}$$

由此就可以构造出一个形如 $Ax = b$ 的方程组。

当我们把 x 也即所有 $f(x, y)$ 都求出来之后，将 f 覆盖到背景图片 S 上，就可以得出合成后的图像。

注意在 (x, y) 处于 f 边缘上时，上式会计算不属于 f 的像素点，此时该像素点取 $\partial\Omega$ 上的像素点。

这里举个例子来说明计算过程。

假设有一个大小是 4*4 的 16 个像素点图片 S

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

我们要插入一个 2*2 的四个像素点的图像 G，插入位置为 6、7、10、11 四个像素点，那么根据公式③有下式成立，其中 $f(x)$ 代表的是合成后图片 f 在 x 处的像素点

$$\begin{cases} f(2) + f(5) + f(7) + f(10) - 4 * f(6) = \text{div}(G(6)) \\ f(3) + f(6) + f(8) + f(11) - 4 * f(7) = \text{div}(G(7)) \\ f(6) + f(9) + f(11) + f(14) - 4 * f(10) = \text{div}(G(10)) \\ f(7) + f(10) + f(12) + f(15) - 4 * f(11) = \text{div}(G(11)) \end{cases}$$

我们要求的是 $f(6), f(7), f(10), f(11)$ ，对于边界如 $f(2)$ ，我们取 $f(2) = S(2)$ （边界不变的条件），这样我们就可以利用矩阵求解这个方程。

D. 程序算法流程

1. 求解前景图像与背景图像的梯度，同时定义感兴趣的区域（ROI），该区域的大小就是前景图像的大小，该区域是在背景图像上的。
2. 将前景图像的梯度图覆盖到背景图像梯度图的 ROI 上，同时对覆盖后的梯度图求散度。

前两部分主要是利用 OpenCV 中的 `filter2D()` 函数来实现的，这部分相对比较简单，所以就直接调用函数实现。

3. 根据公式③构造 $Ax = b$ 中的 A 与 b

A 是一个大型稀疏矩阵，每一行中的非零元素不超过 5 个，这里构建了一个比较简陋的稀疏矩阵类 `Sparse_matrix` 来保存 A 。

（如果 ROI 的范围是 30*30，则 x 的维数是 900*1，那么 A 的维数就是 900*900）

4. 利用 Jacobi Method 求解 x

在求解的过程中，注意迭代次数。在本次实现中暴力求解导致返程求解效率（应当是平方级别的）极其低下，迭代 100 次的解大约需要 30 分钟，迭代 1000 次，可以先去睡一觉，然后再回看效果。但同样的迭代次数少，求解出来的图像效果不好，曾试过只迭代一次，最后输出的图像就像是对 ROI 的区域进行边缘检测。

5. 显示结果

III. 运行结果

A. Jacobi Method 迭代 100 次的结果


见图一

B. Jacobi Method 迭代 1000 次的结果


见图二

C. 对比

从两图中可以看出，在迭代 100 次之后还可以看到比较模糊的边界，但迭代 1000 次之后几乎无法看到明显的边界。此外在求解出来的前景图片中我们可以看出，前景图片的颜色发生了变化，这是因为该算法是尽可能的保留梯度信息，这应当是一种折中。



图一，迭代 100 次



图二，迭代 1000 次

参考文献

- [1] Poisson Image Editing, 2003_sigraph_perez
- [2] <https://blog.csdn.net/hjimce/article/details/45716603>
- [3] <https://blog.csdn.net/u011534057/article/details/68922197>
- [4] <http://eric-yuan.me/poisson-blending/>
- [5] <https://blog.csdn.net/majinlei121/article/details/46831769>